

Intelligent fault diagnosis in transformers based on the analysis of gases dissolved in oil

Otacílio R. Oliveira Filho  Cleison D. Silva  e Raphael B. Teixeira 

Abstract—The early detection of faults in power transformers is crucial for electrical power systems due to the high maintenance cost and the impact of defects in these pieces of equipment. Several fault detection methods based on dissolved gas analysis (DGA) in insulating oil have been developed and standardized. This article presents a DGA database composed of samples collected from transformers over 20 years of operation, in addition to data from consolidated literature. The more than 2000 samples allow for the design of classifiers for thermal and electrical faults in transformers using machine learning (ML). The study details data exploration and evaluates classifiers such as Logistic Regression (LR), Support Vector Machine (SVM), Artificial Neural Networks (ANN), K-Nearest Neighbors (KNN), as well as conventional methods like the Duval Triangle, Rogers Ratios, Key Gas, Doernenburg, and IEC 60599. The results indicate that a hybrid architecture, composed of KNN and ANN classifiers along with the Duval method, shows excellent performance in diagnosing transformer faults.

Index Terms—Power transformers, DGA, machine learning, ANN, KNN, SVM, RL.

I. INTRODUÇÃO

A Matriz energética como fonte de desenvolvimento depende do estado operacional de seus equipamentos, sendo os transformadores de potência ativos fundamentais [1]. Investigações relevantes sobre falhas em transformadores, conduzidas pelo grupo de trabalho Cigré A2.37, apontam para a proeminência de falhas dielétricas. Nos transformadores de subestações se destacam as falhas mecânicas e defeitos elétricos e nos de geração, predominam as falhas térmicas e dielétricas [2].

Um dos métodos preditivos de diagnóstico baseia-se na análise DGA, cujos valores de concentração gasosa apresentam correlação com falhas térmicas e elétricas de transformadores. Contudo, o mapeamento entre padrões gascromatográficos e diferentes tipos falhas resulta em um problema de classificação não-linear com múltiplas classes, o que torna o diagnóstico por esta abordagem um desafio não trivial [3].

A análise DGA pode representar ganhos significativos na detecção de falhas incipientes [4]. Para transformadores em operação, pode-se reduzir consideravelmente o custo de reparos e possibilita a programação de manutenções preventivas e/ou corretivas, reduzindo o tempo de indisponibilidade destes equipamentos [1].

O transformador em seu ciclo de operação está sujeito a sazonalidade de cargas, curto-circuito, descargas atmosféricas, além do envelhecimento natural do equipamento, eventos correlacionados ao surgimento de falhas incipientes [5].

Neste contexto, a análise DGA é utilizada desde 1960 e vários métodos convencionais, inclusive normatizados, foram desenvolvidos a exemplo do triângulo de Duval, Gás chave, relações de Rogers, Doernenburg, IEC 60599 e outros [3]. Contudo, a característica não-linear do problema, dificulta o mapeamento de padrões de concentração gasosa destes métodos e, muitas vezes, apresentam resultados com baixa assertividade ou indeterminações [6] [7]. Por esta razão, o AM se apresenta como alternativa a esta abordagem.

Os inúmeros métodos convencionais evidenciam a relevância do problema e a dificuldade em tratá-lo por abordagens analíticas. Nesse ambiente, se observa esforços para projetar técnicas no contexto de aprendizado de máquina (AM). Esta abordagem é comumente conduzida por algoritmos consagrados de classificação baseados em reconhecimentos de padrões nos dados, tais como: ANN [8], KNN [9], SVM [10] e outros.

Para extração de padrões e correlações das concentrações dos gases, algumas arquiteturas híbridas têm sido utilizadas com diferentes classificadores [10] [11] [12]. Neste sentido, a presente pesquisa visa contribuir para a melhoria da análise DGA observando o desempenho dos classificadores: ANN, KNN, SVM e RL, além dos métodos convencionais.

Nesta pesquisa é apresentada uma base de dados inédita composta 2004 amostras coletadas de transformadores ao longo de 20 anos de operação e de literaturas consolidadas capaz de fornecer padrões dos tipos falhas. Apresenta-se análise detalhada na exploração dos dados, a partir de formas sistemáticas de computação e recursos estatísticos para reconhecimento de falhas em transformadores. Propõe-se ainda uma arquitetura, composta pelos algoritmos ANN e KNN, associado ao triângulo de Duval para a classificação de casos normais, falhas térmicas e elétricas, sendo assim estabelecida como uma abordagem híbrida com elevada assertividade.

A composição desta estrutura híbrida foi definida a partir do desempenho individual dos métodos. Nesta etapa, além das fases de treinamento, sintonia dos hiperparâmetros e certificação dos resultados por validação cruzada, foi verificado o índice *Kappa* de concordância e sensibilidade dos algoritmos.

O artigo está organizando da seguinte forma: a Seção II apresenta os fundamentos teóricos. Na Seção III é apresentada a metodologia de análise gráfica do *dataset*, métodos convencionais, além dos parâmetros de implementação dos algoritmos AM. Na Seção IV apresentam-se e discutem-se os resultados e estudo de caso, e na Seção V são apresentadas as conclusões.

Otacílio Rodrigues Oliveira Filho (otaciliofilho@ufpa.br), Raphael Barros Teixeira (raphaelbt@ufpa.br) e Cleison Daniel Silva (cleison@ufpa.br). PPCA, Programa de Pós-Graduação em Computação Aplicada do Núcleo de Desenvolvimento Amazônico em Engenharia da Universidade Federal do Pará, Tucuruí, Brasil.

II. FUNDAMENTOS

A. Análise DGA

A análise DGA tem por objetivo nortear as tomadas de decisões quando da identificação de falhas incipientes em transformadores de potência [13]. Neste caso, a identificação, a medição e interpretação das concentrações dos gases, além do conhecimento prévio das condições operativas dos equipamentos, são fundamentais para diagnóstico de falhas [3].

Neste contexto, o estudo da análise DGA, tem se mostrado eficiente na detecção de defeitos, pois as concentrações gasosas tendem a se manter no óleo. Logo, variações na temperatura em função da distribuição de energia na vizinhança da falha alteram os produtos das decomposições existentes e por conseguinte as concentrações dos gases [3].

Deste modo, diversos modelos foram desenvolvidos, a exemplo da pesquisa do grupo B87 da IEEE, IEC e CIGRE, além de modelos de abordagem analítica. Onde apresentam as relações entre as concentrações dos gases hidrogênio (H_2), metano (CH_4), etano (C_2H_6), etileno (C_2H_4) e acetileno (C_2H_2) e a temperatura do óleo e os diferentes tipos de falhas, que por sua vez, podem ser de origem térmica ou elétrica [3].

No modelo apresentado na IEEE C57.104, 2019, mostrado na Figura-1, têm-se as correlações entre concentrações, temperatura e os defeitos: descargas parciais (PD), falhas térmicas de baixa, média e alta intensidade (T1, T2 e T3), falhas elétricas de baixa e alta intensidade (D1 e D2), respectivamente, e serão abordadas neste estudo. Exceto as reações catalíticas (R), gases parasitas (S), aquecimento do papel e óleo (O) e carbonização do papel (C) que não fazem parte do escopo desta pesquisa.




Fig. 1: Distribuição da concentração dos gases IEEE C57.104

Os modelos analíticos, ditos métodos convencionais, são utilizados desde a década de 1960 e amplamente aplicados na análise DGA, além disso, existem as arquiteturas baseadas em AM, onde algumas delas serão apresentadas a seguir.

B. Métodos convencionais

1) *Triângulo de Duval 1*: Seus lados expressam percentuais relativos em função da temperatura e energia de falha dos gases CH_4 , C_2H_2 e C_2H_4 . Suas regiões representam os tipos de falhas PD, D1, D2, T1, T2 e T3, além de uma área de falha mista DT (térmicas e elétricas). O método não possui diagnóstico para casos normais [3].

2) *Relações de Rogers*: Faz uso de relações e da correlação destas proporções para diagnósticos. Estratifica casos normais, falhas térmicas e elétricas [3].

3) *Gás chave*: Os gases-chave são aqueles que, em determinado grau de concentração predominante, indicam a presença de diferentes tipos de falhas em transformadores [3].

4) *Doernenburg*: Identifica três tipos de falhas: falha térmica, descarga parcial e arco elétrico. O método faz uso de quatro relações e três pré-condições específicas para em seguida submeter as amostras a análise [3].

5) *IEC 60599*: O método da IEC-60599 faz uso das mesmas relações de Rogers; contudo, apresentam diferenças em alguns valores limites das faixas de análise e diagnóstico, além de não estratificar casos de amostras normais [14].

C. Métodos inteligentes

A análise DGA teve nos diferentes métodos convencionais sua eficiência comprovada, contudo, a dificuldade na extração de padrões para o problema não-linear é refletida em seus resultados, cujos diagnósticos indeterminados e de baixa assertividade são recorrentes [7]. Por esta razão, o estudo de variadas arquiteturas de aprendizado de máquina (AM), associadas a métodos probabilísticos, estatísticos entre outros, estão cada vez mais proeminentes neste segmento [15]. Neste contexto, a presente pesquisa destaca: RL, SVM, ANN e KNN. Além dos algoritmos de apoio: Análise de Componente Principal (PCA), K-means e Kappa de Cohen.

1) *Regressão Logística - RL*: Determina a probabilidade de um evento ocorrer ou de uma entrada pertencer a uma classe específica, modelando a relação entre uma variável dependente e um conjunto de variáveis independentes. A Equação-1 permite a conversão dos valores de entrada em uma escala *logit*, que varia de $-\infty$ a $+\infty$, para valores de probabilidade que variam entre 0 e 1. Onde os pesos $\bar{\beta}$ são ajustados pelo método da máxima verossimilhança [16].

$$f(x, \bar{\beta}) = P(y | x) = \left(\frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} \right). \quad (1)$$

2) *Máquina de Vetores de Suporte - SVM*: Constrói um hiperplano como superfície de decisão que maximiza a margem de separação entre as classes, ideal para problemas de classificação linear. As funções *Kernel* permitem que a SVM lide com problemas não lineares ao transformar os dados para uma dimensão mais alta, retornando a linearidade novamente. As variáveis de relaxamento ζ_i ajustam a posição das amostras em relação aos hiperplanos e permitem performar melhor evitando os ruídos nos dados. A minimização do erro ϵ na Equação-2 demanda valores mínimos para ζ_i no conjunto de treinamento, onde C é uma constante de ajuste [17].

$$\epsilon(\mathbf{w}, x) = \|\mathbf{w}\|^2 + C \sum_{i=1}^n \zeta_i(\mathbf{w}, b). \quad (2)$$

3) *Redes Neurais Artificiais - ANN*: Algoritmo que emula a estrutura de sistemas nervosos, onde as unidades básicas de processamento são chamadas de neurônios, interconectados em camadas, l , e ativados por uma função $\phi(\cdot)$. No treinamento relacionam os valores de entrada e saída, x e y , pela Equação-3. Em um segundo momento, é realizado o teste a partir do vetor de entrada x entregue a ANN e os coeficientes memorizados são recuperados para classificar a nova amostra. Cujo aprendizado é representado pelo conjunto de pesos sinápticos, w , ajustados pelo algoritmo de *backpropagation* [12].

$$y_j^{(l)} = \phi \left(v_j^{(l)} \right) = \phi \left(\sum_{i=0}^p w_{ij}^{(l)} x_{ij}^{(l)} \right). \quad (3)$$

4) *k-ésimos vizinhos mais próximos - KNN*: Considera a hipótese de que dados de mesma classe tendem a se concentrar em uma mesma região, para então atribuir um rótulo a uma nova instância n de acordo com a classe preponderante entre os K vizinhos mais próximos do conjunto de treinamento. Além de possuir capacidade para resolver problemas não lineares a partir de uma base de dados suficientemente grande [18].

D. Algoritmos de apoio

1) *Análise de componentes principais - PCA*: A análise de componentes principais (PCA) é uma técnica multivariada de modelagem da estrutura de covariância que transforma linearmente um conjunto original de variáveis, possivelmente correlacionadas entre si, num conjunto substancialmente menor de variáveis não correlacionadas que contém a maior parte da informação do conjunto original [19].

2) *K-means*: Agrupa dados tentando separar amostras em n grupos de variância semelhantes (*clusters*), ao passo que as semelhanças entre os elementos de grupos distintos sejam as menores possíveis. Na prática, é escolhido o número de K centroides para o agrupamento pré-estabelecido, em seguida associa cada amostra ao centro mais próximo, de modo que a média quadrada da distância euclidiana seja minimizada [20].

3) *Kappa de Cohen*: Métrica estatística que mede a concordância entre classificadores que avaliam os mesmos dados. É particularmente útil, pois leva em consideração a concordância que ocorre ao acaso, o que o torna mais robusto do que simplesmente medir a porcentagem de concordância [21].

III. METODOLOGIA

Uma característica típica no processo DGA, são *datasets* desbalanceados e relativamente pequenos. Neste sentido, a presente pesquisa visa contribuir apresentando uma base de dados robusta, que possui boa capacidade de representação do problema intrínseco.

Composta com cerca de 80% de dados coletados de transformadores ao longo de 20 anos de operação no setor elétrico brasileiro e de literaturas consolidadas [10] [11] [22], a exemplo da IEC TC10. As 2185 amostras iniciais estão distribuídas em 1476 amostras normais, 442 do tipo T (falhas térmicas) e 267, D (falhas elétricas).

A. Pré-processamento dos dados

Os dados foram logaritimizados em função de sua alta variância, fato que permitiu a análise gráfica de sua distribuição.

Na Figura-2 apresenta-se a distribuição dos gases, com maior quantidade de amostras na região de 2 a 4, que se refere a baixas concentrações gasosas, em função do maior número de dados normais, exceto o C_2H_2 , que normalmente possui zero de concentração para casos normais. Neste caso, é importante ressaltar que as amostras com valores nulos (zero) foram atribuídos 0.01 em função da logaritimização do *dataset*.

As amostras discrepantes na região superior da Figura-2, são casos de falhas, que apresentam altas concentrações em função do tipo de defeito. Enquanto as amostras inferiores podem estar relacionadas a *outliers* e serão analisadas a seguir.




Fig. 2: Distribuição de dados logaritimizados - *boxplot*




Fig. 3: Distribuição de dados logaritimizados - 3D

Para estas amostras inferiores, o gráfico da Figura-3 exibe a distribuição espacial do *dataset*, representado pelas componentes principais PC1, PC2 e PC3. No qual, se observa a presença de pequenos grupos de amostras normais na região destacada e permite inferir a presença de dados sensíveis (*outliers*) ao processo de AM. Desta forma, aplicou-se o *K-means*, em toda a base de dados, onde a área destacada formou três *clusters* menores, totalizando 181 amostras, as quais, foram excluídas do *dataset*.

Além disso, é possível observar a existência de um padrão de separabilidade entre classes e embora possua regiões com sobreposição de dados, sugerem a correta classificação das amostras e o seu potencial de representar o proplema DGA.

Sobre este potencial, utilizou-se abordagem de aplicar uma função polinomial de ordem elevada para ajudar a capturar a complexidade dos dados e proporcionar uma representação mais fiel dos padrões observados. Deste modo, aplicou-se a curva de tendência aos percentuais de concentração de cada tipo de gás dentro da mesma amostra em todo o *dataset*, cujo gráfico resultante é semelhante ao da norma C57.104 [3], apresentado na Figura-1 e será discutido na Seção IV.

B. Aplicação dos métodos convencionais

Duval sempre aponta algum tipo de falha, mesmo para amostras normais. O método IEC 60599 não possui diagnóstico normal, enquanto Rogers apresentou baixo desempenho baixo nesta classe. Por este motivo, somente casos de falhas foram apresentadas a estes métodos. Para Doernenburg e Gás chave foram considerados o desempenho de todas as classes.

C. Aplicação dos métodos inteligentes

Nesta aplicação a base de dados foi normalizada a partir da média e desvio padrão para entrada de todos os algoritmos testados e particionada em treinamento (67%) e teste (33%).

1) *Regressão Logística - LR*: Foi utilizado método multinomial, cuja função de perda é definida pela aplicação de entropia cruzada, o hiperparâmetro *class weight* foi definido que todas as classes possuem o mesmo peso, otimizador *lbfgs*, os demais parâmetros foram os *default* do *Sklearn*.

2) *Máquina de Vetores de Suporte - SVM*: Inicialmente foi implementado algoritmo PCA, onde o vetor de entrada foi ampliado de 5 (gases DGA) para 31 dimensões. Das quais, 8 dimensões foram criadas pelos métodos estatísticos de análise exploratória de dados. Outras 20 dimensões, a partir dos dados normalizados, logaritimizados, *sqrtmed* e amostras originais. Além de 3 dimensões criadas pelas relações de Rogers. Para o SVM, foram utilizadas as dez primeiras componentes principais que representam 93% das características originais do *dataset*. Na sintonia dos parâmetros foi utilizado o *GridSearchCV*, cujos ajustes foram $C=100$, $\gamma=0.01$ e $\text{kernel}=rbf$ e certificado por validação cruzada, $CV=5$.

3) *Redes Neurais Artificiais - ANN*: Para atualização dos pesos foi utilizado o método do gradiente estocástico, *batch size* foi igual a 10, para 100 épocas. O otimizador *adam*, auxiliado por uma taxa de aprendizagem igual 0.01, e de decaimento 0.001, além do *clipvalue* igual 0.5. Sobre a disposição de números de camadas e neurônios, a arquitetura 12-12-8-6, ativadas pela função *selu*, inicializador (*kernel*) normal, apresentou excelente desempenho nas fases de treinamento e teste. Na camada de saída optou-se por três neurônios, número de classes desejada, e função de ativação *softmax*, ideal para problemas de múltiplas classes, inicializador (*kernel*) normal e função *categorical crossentropy*.

4) *k-ésimos vizinhos mais próximos - KNN*: Na fase de treinamento foi realizada a sintonia automática, para $K=5$. O método de pesos uniformes apresentou melhor desempenho e adotada a métrica euclidiana para a função de distância. Na escolha do parâmetro *algorithm*, onde o *Sklearn* dispõe de três opções, foi adotado o modo automático que avalia conforme a distribuição dos dados o melhor classificador.

D. Avaliação dos Métodos

A partir da matriz de confusão dos métodos inteligentes, foi calculada a sensibilidade como métrica de avaliação. Além da análise de concordância entre modelos testados, cujo método de *Kappa de Cohen* foi aplicado com ponderação linear.

Nos métodos convencionais, face a vários resultados indeterminados, a avaliação levou em consideração as amostras com diagnóstico, cujas métricas, foram precisão e acurácia.

IV. RESULTADOS

A. Pré-processamento

Na Figura-4, as curvas das concentrações dos gases geradas por uma função polinomial de sexta ordem, permitem observar os padrões das curvas em relação a Figura-1. Entretanto, as extremidades de uma função polinomial de ordem elevada, tendem a sofrer influência dos dados e podem apresentar tendência discrepante ao fenômeno analisado, por este motivo, deve-se desconsiderar seus extremos.

Deste modo, as curvas do H_2 e C_2H_2 , principais marcadores de falhas D2, que apresentam além das inclinações, os percentuais de concentração similares ao padrão esperado em [3].

Além disso, as amplitudes das curvas e os pontos de interseção entre os tipos de gases, seguem padrão semelhante ao da Figura-1. Tais constatações inferem que o *dataset* possui boa capacidade de representação do problema DGA.




Fig. 4: Distribuição da concentração dos gases

B. Resultados dos métodos inteligentes

A representatividade do problema expressa nos dados, permite aos algoritmos extrair os padrões necessários para aprendizado dos classificadores, cujo desempenho serão apresentados a partir das matrizes de confusão mostradas na Tabela-I, onde os resultados de precisão, acurácia e sensibilidade, foram estratificados na Tabela-II.

Para a RL, os 22 casos de falsos negativos contribuíram para uma sensibilidade de 88,89%, o menor dentre os classificadores inteligentes. Entretanto, este método performa melhor que os convencionais.

TABLE I: Matrizes de confusão

Classificador	Classes	Normais	Térmicas	Elétricas
RL	Normais	419	12	11
	Térmicas	13	112	4
	Elétricas	9	2	80
SVM	Normais	427	8	7
	Térmicas	10	114	5
	Elétricas	5	2	84
ANN	Normais	378	17	13
	Térmicas	8	113	2
	Elétricas	1	0	71
KNN	Normais	436	3	3
	Térmicas	8	120	1
	Elétricas	9	1	81

Enquanto os algoritmos RL, SVM e KNN, obtiveram resultados de precisão acima de 94% para os casos normais, a ANN apresentou precisão de 98,61% para a classe minoritária (falhas elétricas), seguida pelo SVM, 92,31%. No desempenho geral, a acurácia dos algoritmos estão acima de 92%. Em ambas as métricas, o KNN se destaca e possui desempenho de 98,64% e 96,22% para classificação de amostras normais (precisão) e desempenho geral (acurácia), respectivamente.

A redução de dimensionalidade por PCA aplicada ao SVM mostrou-se interessante. Pois, seu desempenho, exceto para amostras térmicas, ficaram todos acima de 90%. Onde a precisão para amostras normais foi de 96,61%, para falhas elétricas 92,31%, a acurácia do método foi de 94,41% e a sensibilidade 92,09%. No desempenho de acurácia dos métodos, o SVM é superado apenas pela ANN.

Mais uma vez a análise da sensibilidade foi aplicada e estendida para as falhas térmicas e elétricas, onde os melhores classificadores foram o KNN para falhas térmicas e a ANN nas elétricas.

Outra importante aplicação das matrizes de confusão é a análise de concordância na classificação de amostras, aferida pelo índice *Kappa de Cohen*. Onde a RL e ANN obtiveram 85,18% de concordância, RL e KNN (81,63%), RL e SVM (84,70%), SVM e ANN (92,60%), SVM e KNN (88,81%) e KNN e ANN (92,55%), onde resultados acima de 80% apontam para concordância completa.

C. Resultados dos métodos convencionais

Os métodos convencionais foram implementados em *Python*, cujo desempenho confirmaram às informações contidas nas literaturas pesquisadas. Dentre as quais, observa-se a presença de diagnósticos indeterminados e baixa assertividade de alguns métodos. Contudo, os resultados analíticos dos métodos surpreendem pela capacidade de classificação do problema não-linear de análise DGA.

O método de Rogers apresentou desempenho extremamente baixo para amostras normais, enquanto Duval e IEC 60599 não possuem classificação para esta classe, por este motivo, foram consideradas apenas os resultados para as classificações de

falhas. Coincidentemente apresentaram as melhores precisões para defeitos térmicos.

O Gás chave tende a apresentar baixa acurácia quando aplicado de forma automática, por meio de programação [3] e obteve acurácia de 59,68%. Doernenburg apresentou o melhor desempenho nas falhas elétricas, 87,26%. Enquanto Duval superou, inclusive, os métodos inteligentes nas falhas térmicas, com 96,83% de precisão.

D. Arquitetura híbrida

A proposta de estrutura de análise DGA, foi definida a partir do desempenho individual dos métodos. Está composta pelos algoritmos ANN e KNN, associado ao triângulo de Duval para a classificação de casos normais, falhas térmicas e elétricas.

A arquitetura híbrida, apresentada na Figura-5, consiste em utilizar os classificadores em conjunto, de modo que na etapa para classificação de falha tenhamos um método convencional operando em conjunto com um inteligente. Foram escolhidos o KNN e ANN, e o método convencional de Duval.

Inicialmente, a amostra é apresentada à arquitetura híbrida, que realizará a normalização e logaritimização dos dados, em seguida realizará a análise e emitirá o resultado nas saídas 1 ou 2 ou 3. As saídas 1 (falha T ou D) ou 2 (normal), serão habilitadas no caso de concordância dos algoritmos. No caso de discordância de diagnóstico, a saída 3 é acionada e solicita-se a análise de tendência, onde deve ser verificado o contexto operativo do transformador, por exemplo, se houve aumento das concentrações dos gases ao longo do tempo. Em caso de falha (saída 1), a amostra é entregue a Duval para estratificação da intensidade do tipo de falha.

A forte sensibilidade do KNN para falhas térmicas será complementada com o método do triângulo de Duval que permitirá estratificar a falha térmica em T1, T2 ou T3. O mesmo acontece para falhas elétricas entre a ANN e Duval, que classificará em PD, D1 ou D2.

É importante ressaltar que o método do triângulo Duval emitirá diagnóstico conforme o tipo de falha apontado pelos algoritmos e, em caso de discordância (entre os algoritmos e Duval), a arquitetura híbrida emitirá o resultado T ou D somente. A arquitetura, nomeada Sistema de Diagnóstico Inteligente (SDI) e representada na Figura-31, obteve 98% desempenho na análise de 100 novas amostras, composta por 60 normais, 20 térmicas e 20 elétricas, além da correta classificação no estudo de caso, que será apresentado a seguir.




Fig. 5: Sistema de Diagnóstico Inteligente - SDI.

TABLE II: Quadro comparativo de desempenho das metodologias.

Metodologia	Método	Métrica por classe - Precisão (%)			Métricas do método (%)		Sensibilidade à falhas
		Normais	Térmicas	Elétricas	Acurácia	Sensibilidade	
Convencional	Duval	*	96,83	67,04	**	**	**
	Rogers	*	84,16	33,70	**	**	**
	Gás chave	76,60	11,09	58,05	59,68	28,77	**
	Doernenburg	90,50	58,82	87,26	83,43	69,93	**
	IEC 60599	*	94,57	34,08	**	**	**
Inteligente	RL	94,80	86,82	87,91	92,30	88,89	89,60T e 89,89E
	SVM	96,61	88,37	92,31	94,41	92,09	91,94T e 94,38E
	KNN	98,64	93,02	89,01	96,22	91,78	93,75T e 90,90E
	ANN	92,65	91,87	98,61	93,20	95,34	93,39T e 98,61E

* Precisão não considerada na classe. ** Métrica não considerada no método.

E. Estudo de caso

O transformador de 69/13,8kV e 21,5MVA, que opera na UHE Tucuruí, apresentou em 2023 aumento nas concentrações dos gases CH_4 , C_2H_4 e C_2H_6 , cujos valores estão apresentados na Tabela-III. Nota-se que sucessivas coletas foram realizadas em janeiro e fevereiro para confirmar os resultados. Em março, após reparos, retornou a operação com valores normais.

TABLE III: Amostras gascromatográficas - trafo de 69kV

Data	H2	CH4	C2H4	C2H6	C2H2	Análise - SDI
11.03.2024	1	1	0	0	0	Normal
20.02.2024	22	36	71	64	0	Térmico - T3
19.02.2024	19	38	82	64	0	Térmico - T3
26.01.2024	11	36	59	61	0	Térmico - T3
08.01.2024	111	59	72	72	0	Térmico - T3
21.11.2023	20	44	59	64	0	Térmico - T3
17.11.2022	40	11	13	5	0	Normal
09.11.2021	24	5	11	3	0	Normal

Os resultados DGA propiciaram a tomada de decisão para retirada de operação do transformador para realização de ensaios, como a resistência ôhmica de enrolamento, que identificou alterações na bobina da fase A, inferindo problemas de conexão. Em seguida, foi realizada a abertura do equipamento para inspeção interna. Onde a Figura-6, evidencia aquecimento na mesma fase A do equipamento.

A análise do SDI, obteve diagnóstico de falha térmica T3, conforme indicado na Tabela-III, que sugere temperatura acima de 700°C. O diagnóstico é condizente com as características do tipo de defeito encontrado na inspeção, pois apresenta coloração do metal, inferindo temperatura a cerca de 800°C [14], além de classificar corretamente as amostras normais.



Fig. 6: Conexão frouxa - fonte de aquecimento.

V. CONCLUSÃO

Face à importância do diagnóstico precoce de falhas em transformadores, devido ao elevado custo de manutenção e ao impacto dos defeitos nesses equipamentos no setor elétrico e indústrias, este trabalho colabora através da apresentação de *dataset* e de classificadores de AM sobre o uso da análise DGA. Deste modo, verificou-se que:

- A base de dados utilizada possui boa representatividade do problema, além da capacidade de mapeamento para distinção entre diferentes condições do transformador. As curvas de concentração gasosa sugerem forte similaridade com os padrões pré-definidos na IEEE C57.104, 2019.
- Classificadores SVM podem ser treinados com alta eficiência (94,41%) ao usar métodos estatísticos de análise exploratórias de dados em conjunto com amostras e relações puras dos gases.
- A análise de sensibilidade para falhas, demonstrou que o método probabilístico multinomial da RL possui bom desempenho, contudo inferior aos demais algoritmos.
- O KNN performou inversamente proporcional às distâncias. Para amostras relativamente próximas, classe normal (98,64%), entretanto, nas falhas elétricas, que envolve maiores distâncias, seu desempenho foi de 89,01%.
- O classificador ANN não apresentou dificuldade ao formar dados desbalanceados e de alta variância, além de apresentar excelente desempenho de sensibilidade (98,61%) à falhas elétricas, classe minoritária do *dataset*.

É importante observar que os atributos considerados funcionam bem para os casos estudados, porém é possível que a abordagem necessite de novo treinamento para grupos de equipamentos específicos. Além disso, se o número de amostras não for suficiente para mapeamento das condições, haverá menos informação por tipo de falha, o que pode levar à diagnósticos incorretos e, portanto, perda de acurácia.

Por fim, a pesquisa demonstra que as amostras do *dataset* possuem alta capacidade de generalizar o problema da análise DGA. Além de permitir aos algoritmos a extração de padrões e correlações entre defeitos e os diferentes tipos de gases e concentrações. Deste modo, a arquitetura híbrida, SDI, se apresenta como alternativa no diagnóstico inteligente de falhas em transformadores de potência.

REFERENCES

- [1] O. E. Gouda, S. H. El-Hoshy, and H. H. EL-Tamaly, "Condition assessment of power transformers based on dissolved gas analysis," *IET Generation, Transmission & Distribution*, vol. 13, no. 12, pp. 2299–2310, 2019, DOI: <https://doi.org/10.1049/iet-gtd.2018.6168>.
- [2] S. Tenbohlen, J. Jagers, and F. Vahidi, "Standardized survey of transformer reliability: On behalf of cigre wg a2. 37," in *2017 International Symposium on Electrical Insulating Materials (ISEIM)*, vol. 2, pp. 593–596, IEEE, 2017, DOI: [10.23919/ISEIM.2017.8166559](https://doi.org/10.23919/ISEIM.2017.8166559).
- [3] IEEE-C57.104, "Guide for the interpretation of gases generated in mineral oil immersed transformers," 2019.
- [4] S. Singh and M. Bandyopadhyay, "Dissolved gas analysis technique for incipient fault diagnosis in power transformers: A bibliographic survey," *IEEE Electrical insulation magazine*, vol. 26, no. 6, pp. 41–46, 2010, DOI: [10.1109/MEI.2010.5599978](https://doi.org/10.1109/MEI.2010.5599978).
- [5] H. de Faria Jr, J. G. S. Costa, and J. L. M. Olivas, "A review of monitoring methods for predictive maintenance of electric power transformers based on dissolved gas analysis," *Renewable and sustainable energy reviews*, vol. 46, pp. 201–209, 2015, DOI: <https://doi.org/10.1016/j.rser.2015.02.052>.
- [6] A. Venkatasami and P. Latha, "Application of extreme learning machine in fault classification of power transformer," *Circuits and Systems*, vol. 7, no. 10, pp. 2837–2845, 2016, DOI: [10.4236/cs.2016.710242](https://doi.org/10.4236/cs.2016.710242).
- [7] L. Cheng and T. Yu, "Dissolved gas analysis principle-based intelligent approaches to fault diagnosis and decision making for large oil-immersed power transformers: A survey," *Energies*, vol. 11, no. 4, p. 913, 2018, DOI: <https://doi.org/10.3390/en11040913>.
- [8] M. Amora, O. Almeida, A. Braga, F. Barbosa, S. Lima, and L. Lisboa, "Decompositional rule extraction from artificial neural networks and application in analysis of transformers," in *2009 15th International Conference on Intelligent System Applications to Power Systems*, pp. 1–6, IEEE, 2009, DOI: [10.1109/ISAP.2009.5352932](https://doi.org/10.1109/ISAP.2009.5352932).
- [9] L. Qiao, R. Ran, H. Wu, Q. Zhou, S. Liu, and Y. Liu, "Imputation method of missing values for dissolved gas analysis data based on iterative knn and xgboost," in *Proceedings of the 2018 International Conference on Algorithms, Computing and Artificial Intelligence*, pp. 1–7, 2018, DOI: <https://doi.org/10.1145/3302425.3302447>.
- [10] A. Kirkbas, A. Demircali, S. Koroglu, and A. Kizilkaya, "diagnosis of oil-immersed power transformers using common vector approach," *Electric Power Systems Research*, vol. 184, p. 106346, 2020, DOI: <https://doi.org/10.1016/j.epsr.2020.106346>.
- [11] M. M. Islam, G. Lee, and S. N. Hettiwatte, "A nearest neighbour clustering approach for incipient diagnosis of power transformers," *Electrical Engineering*, vol. 99, pp. 1109–1119, 2017, DOI: <https://doi.org/10.1007/s00202-016-0481-3>.
- [12] A. Salami and P. Pahlevani, "Neural network approach for fault diagnosis of transformers," in *2008 International Conference on Condition Monitoring and Diagnosis*, pp. 1346–1349, IEEE, 2008, DOI: [10.1109/CMD.2008.4580518](https://doi.org/10.1109/CMD.2008.4580518).
- [13] S. Kim, S.-H. Jo, W. Kim, J. Park, J. Jeong, Y. Han, D. Kim, and B. D. Youn, "A semi-supervised autoencoder with an auxiliary task (saat) for power transformer diagnosis using dissolved gas analysis," *IEEE Access*, vol. 8, pp. 178295–178310, 2020, DOI: [10.1109/ACCESS.2020.3027830](https://doi.org/10.1109/ACCESS.2020.3027830).
- [14] IEC-60599, "Mineral oil-filled electrical equipment in service – guidance on the interpretation of dissolved and free gases analysis," 2015.
- [15] J. J. de Oliveira Neto, G. V. R. Xavier, D. O. Cardoso, and J. C. Canuto, "Comparação de classificadores na análise de gases dissolvidos," *Simpósio Brasileiro de Sistemas Elétricos-SBSE*, vol. 1, no. 1, 2020, DOI: <https://doi.org/10.48011/sbse.v1i1.2163>.
- [16] Q. Wang, S. Yu, X. Qi, Y. Hu, W. Zheng, J. Shi, and H. Yao, "Overview of logistic regression model analysis and application," *Zhonghua yu fang yi xue za zhi [Chinese journal of preventive medicine]*, vol. 53, no. 9, pp. 955–960, 2019, DOI: <https://doi.org/10.3760/cma.j.issn.0253-9624.2019.09.018>.
- [17] S. Ge, R. Wang, and D. Yu, "Classification of four-class motor imagery employing single-channel electroencephalography," *PloS one*, vol. 9, no. 6, p. e98019, 2014, DOI: <https://doi.org/10.1371/journal.pone.0098019>.
- [18] F. Lotte, M. Congedo, A. Lécuyer, F. Lamarche, and B. Arnaldi, "A review of classification algorithms for eeg-based brain-computer interfaces," *Journal of neural engineering*, vol. 4, no. 2, p. R1, 2007, DOI: [10.1088/1741-2560/4/2/R01](https://doi.org/10.1088/1741-2560/4/2/R01).
- [19] M. Greenacre, P. J. Groenen, T. Hastie, A. I. d'Enza, A. Markos, and E. Tuzhilina, "Principal component analysis," *Nature Reviews Methods Primers*, vol. 2, no. 1, p. 100, 2022, DOI: <https://doi.org/10.1038/s43586-023-00209-y>.
- [20] M. M.-T. Chiang and B. Mirkin, "Experiments for the number of clusters in k-means," in *Portuguese conference on artificial intelligence*, pp. 395–405, Springer, 2007, DOI: <https://doi.org/10.1007/978-3-540-77002-2-33>.
- [21] A. Ben-David, "About the relationship between roc curves and cohen's kappa," *Engineering Applications of Artificial Intelligence*, vol. 21, no. 6, pp. 874–882, 2008, DOI: <https://doi.org/10.1016/j.engappai.2007.09.009>.
- [22] E. Li, "Dissolved gas data in transformer oil— diagnosis of power transformers with membership degree," *IEEE dataport*, 2019, DOI: [10.1109/ACCESS.2019.2902299](https://doi.org/10.1109/ACCESS.2019.2902299).



Otacilio R. O. Filho - The author is a student in the PPCA, a Graduate Program in Applied Computing at the Amazonian Development Nucleus in Engineering of the Federal University of Pará (2025). With experience in transformer maintenance, DGA analysis, and Thermography (Eletronorte 2005-2025). Holds CAT II certification from ITC (2023). Graduated in Electrical Engineering from the Federal University of Pará (2014) and as an Electrotechnical Technician from the Federal Institute of Piauí (1995). otaciliofilho@ufpa.br.



Cleison D. Silva - The author holds a PhD in Automation and Systems Engineering from the Federal University of Santa Catarina (2017) and a Master's degree in Electrical Engineering from the Federal University of Pará (2008). He is a researcher and advisor in the Graduate Program in Applied Computing (PPCA). With consolidated experience in the areas of Electrical and Computer Engineering, his research and contributions focus on Electronics, Systems and Controls, Machine Learning, and Biomedical Signal Processing. cleison@ufpa.br.



Raphael Barros Teixeira - The author holds a PhD in Electrical Engineering from the Federal University of Pará (2019), where he works as an engineering lecturer at the Tucuruí Campus. He is a professor, researcher, and the current Coordinator of the Graduate Program in Applied Computing (PPCA). His experience in electrical and computer engineering focuses on electronics, control, and computational intelligence. raphaelbt@ufpa.br.